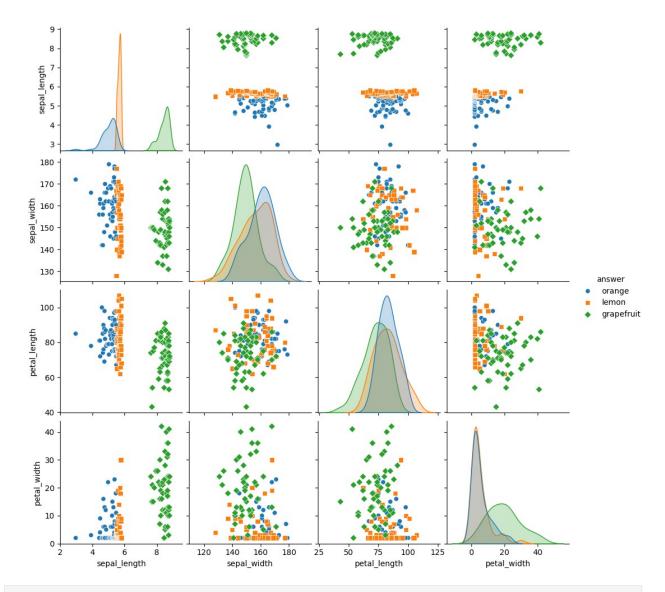
Лабораторная работа 3

Метрические методы классификации

```
# Подгрузка данных
!wget https://raw.githubusercontent.com/WaisShams/ai ml 1/main/data
%20set/citrus.data
--2024-05-13 22:35:05--
https://raw.githubusercontent.com/WaisShams/ai ml 1/main/data%20set/
citrus.data
Resolving raw.githubusercontent.com (raw.githubusercontent.com)...
185.199.108.133, 185.199.109.133, 185.199.110.133, ...
Connecting to raw.githubusercontent.com (raw.githubusercontent.com)
185.199.108.133|:443... connected.
HTTP request sent, awaiting response... 200 OK
Length: 3353 (3.3K) [text/plain]
Saving to: 'citrus.data'
citrus.data
                  0s
2024-05-13 22:35:05 (38.5 MB/s) - 'citrus.data' saved [3353/3353]
import pandas as pd
import numpy as np
data source = 'citrus.data'
d = pd.read table(data source, delimiter=',',
                 header=None,
                 names=['sepal length', 'sepal width',
                       'petal_length','petal_width','answer'])
d.head()
{"summary":"{\n \"name\": \"d\",\n \"rows\": 150,\n \"fields\": [\n
       \"column\": \"sepal length\",\n \"properties\": {\n
\"dtype\": \"number\",\n \"std\": 1.5198053919927383,\n
                      \"max\": 8.79,\n \"num unique values\":
\"min\": 2.96,\n
            \"samples\": [\n
                                     8.53,\n
101,\n
                                                     5.69,\n
             ],\n \"semantic type\": \"\",\n
7.72\n
\"description\": \"\"\n
                                               \"column\":
                          }\n },\n {\n
\"sepal_width\",\n \"properties\": {\n
                                               \"dtype\":
\"number\",\n
\"max\": 179,\n
                   \"std\": 10,\n \"min\": 128,\n
                   \"num_unique_values\": 44,\n
                        139,\n
\"samples\": [\n
                                       178,\n
                                                      177\n
```

```
\"semantic_type\": \"\",\n \"description\": \"\"\n
1,\n
}\n },\n {\n \"column\": \"petal_length\",\n
\"properties\": {\n \"dtype\": \"number\",\n \"std\":
11,\n \"min\": 43,\n \"max\": 107,\n \"num_unique_values\": 45,\n \"samples\": [\n 77,\n 83,\n 104\n ],\n \"semantic_type\": \"\",\n \"description\": \"\"\n }\n {\n \"column\":
                                                                      77.\n
\"petal_width\",\n \"properties\": {\n \"dtype\": \"number\",\n \"std\": 9,\n \"min\": 2,\n \"max\": 42,\n \"num_unique_values\": 33,\n \"samples\": [\n 32,\n 18,\n 28\n ],\n
\"semantic_type\": \"\",\n
                                     \"description\": \"\"\n
                                                                       }\
n },\n {\n \"column\": \"answer\",\n \"properties\":
        \"dtype\": \"category\",\n \"num_unique_values\":
{\n
           \"samples\": [\n \"orange\",\n
3,\n
\"lemon\",\n \"grapefruit\"\n ],\n
\"semantic_type\": \"\",\n \"description\": \"\"\n
                                                                       }\
     }\n ]\n}","type":"dataframe","variable_name":"d"}
d.info()
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 150 entries, 0 to 149
Data columns (total 5 columns):
 #
                     Non-Null Count
     Column
                                        Dtype
- - -
     sepal length 150 non-null
 0
                                        float64
 1
     sepal width
                     150 non-null
                                        int64
 2
     petal length 150 non-null
                                       int64
 3
     petal_width 150 non-null
                                        int64
                    150 non-null
     answer
                                        object
dtypes: float64(1), int64(3), object(1)
memory usage: 6.0+ KB
import seaborn as sb
%matplotlib inline
sb.pairplot(d, hue='answer', markers=["o", "s", "D"])
<seaborn.axisgrid.PairGrid at 0x7eacb2211f60>
```



```
from sklearn.neighbors import KNeighborsClassifier

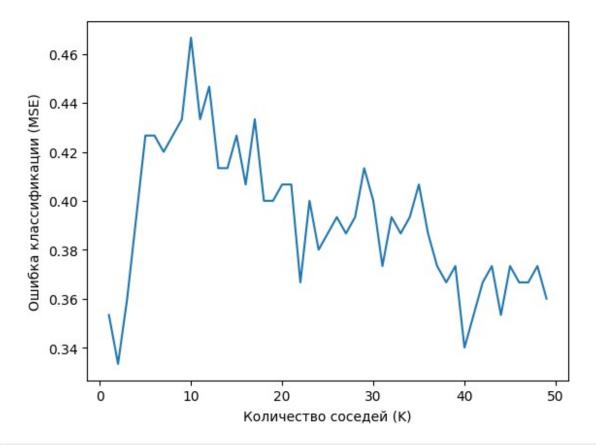
X_train = d[['sepal_length', 'sepal_width', 'petal_length', 'petal_width']]
y_train = d['answer']

K = 3

# Создание и настройка классификатора
knn = KNeighborsClassifier(n_neighbors=K)
# построение модели классификатора (процедура обучения)
knn.fit(X_train.values, y_train)

# Использование классификатора
# Объявление признаков объекта
X_test = np.array([[1.2, 1.0, 2.8, 1.2]])
# Получение ответа для нового объекта
```

```
target = knn.predict(X test)
print(target)
['grapefruit']
from sklearn.model selection import cross val score
import matplotlib.pyplot as plt
# Значения параметра К
k list = list(range(1,50))
# Пустой список для хранения значений точности
cv scores = []
# В цикле проходим все значения К
for K in k list:
    knn = KNeighborsClassifier(n neighbors=K)
    scores = cross val score(knn, d.iloc[ : , 0:4 ], d['answer'],
cv=10, scoring='accuracy')
    cv scores.append(scores.mean())
# Вычисляем ошибку (misclassification error)
MSE = [1-x \text{ for } x \text{ in } cv \text{ scores}]
# Строим график
plt.plot(k list, MSE)
plt.xlabel('Количество соседей (K)');
plt.ylabel('Ошибка классификации (MSE)')
plt.show()
# Ищем минимум
k \min = \min(MSE)
# Пробуем найти прочие минимумы (если их несколько)
all k \min = []
for i in range(len(MSE)):
    if MSE[i] <= k min:</pre>
        all k min.append(k list[i])
# печатаем все К, оптимальные для модели
print('Оптимальные значения K: ', all k min)
```



Оптимальные значения К: [2]

Палитры, которые можно использовать для визуализации

```
print(sorted(list(plt.colormaps)))

['Accent', 'Accent_r', 'Blues', 'Blues_r', 'BrBG', 'BrBG_r', 'BuGn', 'BuGn_r', 'BuPu', 'BuPu_r', 'CMRmap', 'CMRmap_r', 'Dark2', 'Dark2_r', 'GnBu', 'GnBu_r', 'Greens', 'Greens_r', 'Greys', 'Greys_r', 'OrRd', 'OrRd_r', 'Oranges', 'Oranges_r', 'PRGn', 'PRGn_r', 'Paired', 'Paired_r', 'Pastell', 'Pastell_r', 'Pastel2', 'Pastel2_r', 'PiYG', 'PiYG_r', 'PuBu', 'PuBuGn', 'PuBuGn_r', 'PuBu_r', 'PuOr', 'PuOr_r', 'PuRd', 'PuRd_r', 'Purples', 'Purples_r', 'RdBu', 'RdBu_r', 'RdGy', 'RdGy_r', 'RdPu', 'RdPu_r', 'RdYlBu', 'RdYlBu_r', 'RdYlGn', 'RdYlGn', 'RdYlGn_r', 'Set3', 'Set3_r', 'Spectral', 'Set1_r', 'Set1_r', 'Set2', 'Set2_r', 'Set3', 'Set3_r', 'Spectral', 'YlGn_r', 'YlOrBr', 'YlOrBr_r', 'YlOrRd', 'YlOrRd_r', 'afmhot', 'afmhot_r', 'autumn', 'autumn_r', 'binary', 'binary_r', 'bone', 'bone_r', 'brg', 'brg_r', 'bwr', 'bwr_r', 'cividis', 'cividis_r', 'cool', 'cool_r', 'coolwarm', 'coolwarm_r', 'copper', 'copper_r', 'crest', 'crest_r', 'cubehelix', 'gist_earth_r', 'gist_gray', 'gist_gray_r', 'gist_rainbow',
```

```
'gist_rainbow_r', 'gist_stern', 'gist_stern_r', 'gist_yarg',
'gist_yarg_r', 'gnuplot', 'gnuplot2', 'gnuplot2_r', 'gnuplot_r',
'gray', 'gray_r', 'hot', 'hot_r', 'hsv', 'hsv_r', 'icefire',
'icefire_r', 'inferno', 'inferno_r', 'jet', 'jet_r', 'magma',
'magma_r', 'mako', 'mako_r', 'nipy_spectral', 'nipy_spectral_r',
'ocean', 'ocean_r', 'pink', 'pink_r', 'plasma', 'plasma_r', 'prism',
'prism_r', 'rainbow', 'rainbow_r', 'rocket', 'rocket_r', 'seismic', 'seismic_r', 'spring', 'spring_r', 'summer', 'summer_r', 'tab10', 'tab10_r', 'tab20', 'tab20_r', 'tab20b_r', 'tab20c', 'tab20c_r', 'terrain', 'terrain_r', 'turbo', 'turbo_r', 'twilight', 'twilight_r', 'twilight_shifted_r', 'viridis',
'viridis_r', 'vlag', 'vlag r', 'winter', 'winter r']
dX = d.iloc[:,0:4]
dy = d['answer']
plot_markers = ['r*', 'g^', 'bo']
answers = dy.unique()
# Создаем подграфики для каждой пары признаков
f, places = plt.subplots(4, 4, figsize=(16,16))
fmin = dX.min()-0.5
fmax = dX.max()+0.5
plot step = 0.05
# Обходим все subplot
for i in range(0,4):
     for j in range(0,4):
           # Строим решающие границы
           if(i != j):
                 xx, yy = np.meshgrid(np.arange(fmin[i], fmax[i],
plot step),
                                             np.arange(fmin[j], fmax[j], plot_step))
                 model = KNeighborsClassifier(n neighbors=13)
                 model.fit(dX.iloc[:, [i,j]].values, dy)
                 p = model.predict(np.c_[xx.ravel(), yy.ravel()])
                 p = p.reshape(xx.shape)
                 p[p==answers[0]] = 0
                 p[p==answers[1]] = 1
                 p[p==answers[2]] = 2
                 p=p.astype('int32')
                 places[i,j].contourf(xx, yy, p, cmap='Pastel1')
           # Обход всех классов
           for id answer in range(len(answers)):
                 idx = np.where(dy == answers[id answer])
                       places[i, j].hist(dX.iloc[idx].iloc[:,i],
```

